

Analyse et traitement des données textuelles



Mise en bouche

Assortiment de vins à l'aide de données textuelles



→


	<i>dry</i>	<i>flower</i>	<i>sagebrush</i>	<i>elegant</i>	<i>tarragon</i>	<i>pepper</i>	<i>tangy</i>	<i>light-bodied</i>
x_1	0.1	0.5	-0.8	-0.8	0.1	0.3	0.4	0.8
x_2	-0.8	0.2	0.3	-1.1	0.3	0.1	-1.4	-0.2
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_{300}	-1.1	-0.2	-0.2	-2.2	-0.2	-0.5	-1.3	-0.7

↘

This is a complete wine, with tannins and black fruits showing structure and ripeness. It has a firm core that will soften over the next few months. Drink from 2023.

—ROGER VOSS


<https://www.winemag.com/>



Source:




Roald Schuring
Dec 23, 2019 · 7 n




Vectoriser, ce n'est pas encoder des mots, c'est construire un espace où le sens devient mesurable.

<https://www.amazon.com/grocery-breakfast-foods-snacks-organic>

Les différents concepts




Plan




Obtention d'un corpus

Trois approches possibles pour collecter des données textuelles



Plan



2. Découpage en Tokens

Exemple

Tokenize on
rules

Let	's	tokenize	!	Is	n't	this	easy	?
-----	----	----------	---	----	-----	------	------	---

Tokenize on
punctuation

Let	'	s	tokenize	!	Isn	'	t	this	easy	?
-----	---	---	----------	---	-----	---	---	------	------	---

Tokenize on
white spaces


Let's	tokenize!	Isn't	this	easy?
-------	-----------	-------	------	-------

Let's tokenize! Isn't this easy?

<https://blog.floydhub.com/tokenization-nlp/>

2. Découpage en Tokens


Représentation « Bag of Words »



<https://okan.cloud/posts/2021-04-08-text-vectorization-using-python-term-document-matrix/>

2. Découpage en Tokens

Librairie python



NLTK

**Unsupervised Multilingual Sentence
Boundary Detection**

Tibor Kiss*
Ruhr-Universität Bochum


Jan Strunk**
Ruhr-Universität Bochum

Natural Language Toolkit

<https://www.nltk.org/>

<https://www.nltk.org/api/nltk.tokenize.punkt.html>

Plan



3. Term-document Matrix (TDM)

Représentation en matrice de tokens


-  B. Sanders - [Combating, climate, change]
-  H. Clinton - [Let, start, the, combat, of, climate, change]
-  D. Trump - [Building, a, wall, letting, them, pay, for, the, wall]

tokens

	combating	climate	change	let	start	combat	of	building	a	wall	letting	them	pay	for	the
Trump	0	0	0	0	0	0	0	1	1	2	1	1	1	1	1
Sanders	1	1	1	0	0	0	0	0	0	0	0	0	0	0	0
Clinton	0	1	1	1	1	1	1	0	0	0	0	0	0	0	0

Matrice : 3 documents x 15 tokens

Plan



4. Réduction de la dimensionnalité

Pourquoi réduire le nombre de colonnes ?

- La dimensionnalité est souvent **très élevée**
- Le nombre de colonnes peut excéder le nombre de lignes
 - Difficulté algorithmique potentielle
- **Réduction de la taille** du dictionnaire
 - **Nettoyage** du corpus (retrait des chiffres, harmonisation de la casse, etc.)
 - Certains mots ne sont pas porteurs de sens (**stopwords**)
 - Certains mots sont issus de la même forme canonique (**lemmatisation**)
 - Certains mots partagent la même racine (**racinisation**)
 - Certains mots sont **synonymes** ou recouvrent le même concept
 - Certains mots apparaissent **très souvent** / **très rarement**

4. Réduction de la dimensionalité

a) Nettoyage du corpus

- Harmonisation de la **casse**
 - « Tout en minuscule »
- Suppression de la **ponctuation** et des \n
 - Si la ponctuation est encore présente après Tokenization
- Suppression des **nombre**s
 - Sauf dans certains contextes où ceux-ci peuvent s'avérer utile
- Utilisation d'un **correcteur** orthographique
 - Par exemple, pour des tweets. Supprimer les erreurs permet de réduire la liste des termes

4. Réduction de la dimensionalité

b) Retrait des mots vides (stopwords)

Exemple mots vides en français

alors au aucuns aussi autre avant avec avoir bon car ce cela
ces ceux chaque ci comme comment dans des du dedans dehors depuis
devrait doit donc dos début elle elles en encore essai est et eu
fait faites fois font hors ici il ils je juste la le les leur là ma
maintenant mais mes mien moins mon mot même ni nommés notre nous ou
où par parce pas peut peu plupart pour pourquoi quand que quel quelle
quelles quels qui sa sans ses seulement si sien son sont sous soyez
sujet sur ta tandis tellement tels tes ton tous tout trop très tu
voient vont votre vous vu ça étaient état étions été être

<https://www.ranks.nl/stopwords/french>

NB: Liste à compléter ou restreindre en fonction du domaine d'application

4. Réduction de la dimensionalité

b) Corpus de mots vides



https://www.nltk.org/nltk_data/

73. *Stopwords Corpus* [[download](#) | [source](#)]

id: stopwords; size: 34276; author: ; copyright: ; license: ;

▼ stopwords

basque

catalan

chinese

hebrew

hinglish

bengali

nepali

arabic

```
from nltk.corpus import stopwords
```


4. Réduction de la dimensionalité

c) Lemmatisation et Racinisation

- Motivation:
 - Les mots « **Etude** » et « **Etudier** » représentent 2 colonnes différentes car il s'agit de Tokens distincts
 - Cependant, on pourrait réduire la dimension en les comptant sous une même colonne
 - La taille de la matrice serait plus petite
 - La matrice serait moins « sparse »
 - Les deux tokens ont la même signification
- Deux solutions communes :
lemmatisation ou racinisation (stemming)

4. Réduction de la dimensionalité

c) Lemmatisation vs Racinisation

Token	contexte	Lemma	Stem
Livre	<i>livrer un colis</i>	livrer	livr-
Livre	<i>lire un livre</i>	livre	livr-
Somme	<i>sommer les coûts</i>	sommer	somm-
Somme	<i>la somme de 5+3</i>	somme	somm-

- Lemmatisation utilise le contexte, plus précis et plus interprétable
- Racinisation utilise une liste de règles, souvent plus rapide

4. Réduction de la dimensionnalité

d) Filtrage par fréquence

- Certains termes sont présents dans « presque » tous les documents
 - Fréquence trop élevée
 - Permet de cerner le domaine, mais pas de discriminer les documents
- Certains termes ne sont présents que dans de « très rares » documents
 - Ne permettent pas de caractériser une différence significative entre les documents
- Le choix des « seuils » reste arbitraire

4. Réduction de la dimensionalité

Les 4 étapes de réduction

	Combating	climate	change	Let	start	combat	of	Building	a	wall	letting	them	pay	for	the
Trump	0	0	0	0	0	0	0	1	1	2	1	1	1	1	1
Sanders	1	1	1	0	0	0	0	0	0	0	0	0	0	0	0
Clinton	0	1	1	1	1	1	1	0	0	0	0	0	0	0	0

15 tokens

	combating	climate	change	let	start	combat	of	building	a	wall	letting	them	pay	for	the
Trump	0	0	0	0	0	0	0	1	1	2	1	1	1	1	1
Sanders	1	1	1	0	0	0	0	0	0	0	0	0	0	0	0
Clinton	0	1	1	1	1	1	1	0	0	0	0	0	0	0	0

Après (a)
15 tokens

	combating	climate	change	let	start	combat	building	wall	letting	pay
Trump	0	0	0	0	0	0	1	2	1	1
Sanders	1	1	1	0	0	0	0	0	0	0
Clinton	0	1	1	1	1	1	0	0	0	0

Après (b)
10 tokens

	combat	climat	chang	let	start	build	wall	pay
Trump	0	0	0	1	0	1	2	1
Sanders	1	1	1	0	0	0	0	0
Clinton	1	1	1	1	1	0	0	0

Après (c)
8 tokens

	combat	climat	chang	wall	let
Trump	0	0	0	2	1
Sanders	1	1	1	0	0
Clinton	1	1	1	0	1

Après (d)
5 tokens

4. Réduction de la dimensionnalité

« Insights » dérivés de la matrice TDM

Clustering des idéologies politiques

	combat	climat	chang	wall	let
Trump	0	0	0	2	1
Sanders	1	1	1	0	0
Clinton	1	1	1	0	1


bruit

clusters



Réduction supplémentaire possible
avec l'utilisation de n-grams


Plan




5. Vectorisation

Représentation vectorielle des documents

Exemple Twitter



Exemple Amazon



La notion de « Document embeddings » et « Word embedding »

5. Vectorisation

Méthode 1 : TF-IDF

- Associer aux tokens des poids pour **représenter leur valeur discriminante**
 - Tokens apparaissant dans tous les documents n'ont pas de valeur discriminante
 - Tokens apparaissant dans seulement un document n'ont pas de valeur discriminante
 - Tokens apparaissant **souvent dans un sous-ensemble de documents** ont une grande valeur discriminante
- Plusieurs méthodes existent pour calculer ces poids
 - **Importance** d'un token dans un document
 - **Spécificité** d'un token dans un corpus
 - Méthode la plus connue: **tf** x **idf**

5. Vectorisation

Exemple : article sur la COVID-19

Titre article 1 - *Incubation period : risk study on the mean incubation period*

Titre article 2 – *Mean low risk period*

Titre article 3 – *The transmission risk : low transmissions*

TDM – Fréquence absolue

	incubation	period	assess	mean	low	risk	transmission
Article 1	2	2	1	1	0	1	0
Article 2	0	1	0	1	1	1	0
Article 3	0	0	0	0	1	1	2

5. Vectorisation

Exemple : TF = fréquence absolue VS relative

TDM – Fréquence absolue

	incubation	period	assess	mean	low	risk	transmission
Article 1	2	2	1	1	0	1	0
Article 2	0	1	0	1	1	1	0
Article 3	0	0	0	0	1	1	2

TDM – Fréquence relative

	incubation	period	assess	mean	low	risk	transmission
Article 1	1	1	1/2	1/2	0	1/2	0
Article 2	0	1	0	1	1	1	0
Article 3	0	0	0	0	1/2	1/2	1

5. Vectorisation

Méthode 1 : TF-IDF - mesure de la spécificité


- **Discriminer** les tokens qui apparaissent dans beaucoup de documents
- Calculer la spécificité à partir du **logarithme de la distribution**

$$s_i = \log\left(\frac{|D|}{|D_i|}\right)$$

où $|D_i|$ représente le nombre de documents contenant le token i , et $|D|$ le nombre total de documents

- Spécificité nulle pour un token appartenant à tous les documents

$$|D_i| = |D| \Rightarrow s_i = \log 1 = 0$$



5. Vectorisation

Exemple : IDF, mesure de spécificité

TDM – TF (importances relatives) et IDF (spécificité)

	incubation	period	assess	mean	low	risk	transmission
Article 1	1	1	1/2	1/2	0	1/2	0
Article 2	0	1	0	1	1	1	0
Article 3	0	0	0	0	1/2	1/2	1
Specificity	1,1	0,41	1,1	0,41	0,41	0	1,1

5. Vectorisation

Exemple : Multiplier pour obtenir le TF-IDF

$$w_{i,j} = tf_{i,j} \times \log \left(\frac{N}{df_i} \right)$$

$tf_{i,j}$ = number of occurrences of i in j
 df_i = number of documents containing i
 N = total number of documents

TDM – scores TF-IDF

	incubation	period	assess	mean	low	risk	transmission
Article 1	1,1	0,41	0,55	0,205	0	0	0
Article 2	0	0,41	0	0,41	0,41	0	0
Article 3	0	0	0	0	0,205	0	1,1


5. Vectorisation

Exemple : Multiplier pour obtenir le TF-IDF

TDM – scores TF-IDF

	incubation	period	assess	mean	low	risk	transmission
Article 1	1,1	0,41	0,55	0,205	0	0	0
Article 2	0	0,41	0	0,41	0,41	0	0
Article 3	0	0	0	0	0,205	0	1,1

Exemple de visualisation



5. Vectorisation

Limites de la vectorisation classique (TF-IDF)

1. Perte du contexte

Chaque mot est traité indépendamment.

Impossible de distinguer banque (rivière) vs banque (finance).

2. Pas de relations sémantiques

“chat” et “félin” sont totalement différents dans l’espace vectoriel.

5. Vectorisation

Limites de la vectorisation classique (TF-IDF)

3. Vecteurs gigantesques

Une dimension par mot → espace très large.

Sparsité extrême : des milliers de zéros.

4. Ignorent l'ordre des mots

Le chien mord l'homme = L'homme mord le chien

5. Vectorisation

Alternative: les « Embeddings »

- **Représentations denses:** vecteurs compacts (ex. 300–1024 dimensions), sans sparsité.
- **Appris automatiquement :** les vecteurs sont optimisés par un modèle (Word2Vec, GloVe, BERT, etc.).
- **Certains intègrent le contexte (polysémie) :**
Je développe une application en **Java**. : vecteur proche de python
Je voudrais voyager à **Java** en Indonésie : vecteur proche de Bali


5. Vectorisation

Méthode 2 : Doc2Vec

- Développé par Google (Mikolov)
- Réseaux de neurones à 2 couches (Deep Learning)
- Bibliothèque python: Gensim
- Extension du Word2Vec

5. Vectorisation

Word2Vec : idée générale



On va s'entraîner à prédire un mot (intelligence) à l'aide d'un mot proche (artificial)

5. Vectorisation

Comparaison : TF-IDF vs Doc2Vec

TF-IDF

- Idéal pour des corpus de taille modeste : la norme avant 2013
- Vocabulaire focus sur un sujet
- Modèle simple et interprétable

Doc2Vec

- Idéal pour des corpus de taille ultra large : la norme après 2013
- Vocabulaire très large et varié
- Modèle complexe et long à entraîner

5. Vectorisation

Limite restante de Word2Vec : la polysémie

Word2Vec apprend **une seule représentation (un seul vecteur)** par mot.

Je développe une application en **Java**. : vecteur proche de python

Je voudrais voyager à **Java** en Indonésie : vecteur proche de Bali

- Il doit “**mélanger**” tous les usages du mot port dans un seul vecteur.
- Ce vecteur **reflète la moyenne** des contextes : maritime + obligation + informatique.
- Résultat : le vecteur n’est jamais parfaitement adapté à aucun sens particulier.

5. Vectorisation

Méthode 3 : BERT

BERT = Bidirectional Encoder Representations from Transformers.

C'est un modèle de langage basé sur l'architecture **Transformer (partie encodeur)**


Avec Word2Vec :

- un mot → un seul vecteur (pas de contexte)

Avec BERT :

- un mot → un vecteur différent *dans chaque phrase*, selon le contexte.

Plan



6. Calcul de similarité

Propriété d'une mesure de similarité

- Non-négativité $\text{sim}(i, j) \geq 0 \quad \forall i, j$
- Symétrie $\text{sim}(i, j) = \text{sim}(j, i) \quad \forall i, j$
- Maximalité $\text{sim}(i, i) \geq \text{sim}(i, j) \quad \forall i, j$

Possibilité de normaliser entre 0 et 1

6. Calcul de similarité

Exemple : « Cosine Similarity »

- Ne s'intéresse qu'aux **cooccurrences**
- Permet de comparer des documents de longueurs différentes (normalisation)
- Génère une matrice de similarité $C \times C$

