

Analyse et traitement des données textuelles




**La bière,
est-ce un concept
de gauche ou de droite ?**




<https://degaucheoudedroite.delemazure.fr/>

Peut-on mesurer l'idéologie à partir de des réseaux sociaux ?



<https://cvandekerckh.github.io/mythesis/wallonie.html>

Le concept clef : la vectorisation



<https://projector.tensorflow.org/>

Vectoriser pour... recommander des vins :)



Source:  Roald Schuring
Dec 23, 2019 · 7 n

<https://www.winemag.>

Vectoriser pour... recommander des vins :)



Source:



Roald Schuring
Dec 23, 2019 · 7 n

<https://www.winemag.com/>

Vectoriser pour... recommander des vins :)



Source:



Roald Schuring

Dec 23, 2019 · 7 n

<https://www.winemag.com/>



<https://www.amazon.com/grocery-breakfast-foods-snacks-organic>

Vectoriser pour... recommander des vins :)




Source:



Roald Schuring
Dec 23, 2019 · 7 n



<https://www.winemag.com/>





<https://www.amazon.com/grocery-breakfast-foods-snacks-organic>

Vectoriser pour... recommander des vins :)

Source:  Roald Schuring
Dec 23, 2019 · 7 n



<https://www.winemag.com/>



<https://www.amazon.com/grocery-breakfast-foods-snacks-organic>

Que faire avec cette proximité ?




Automatiser
le codage
thématique
d'entretien.



Retrouver
des documents
similaires.



Comparer
des discours.




Mesurer
la proximité
idéologique.

Le vrai combo :

Vectoriser + Classification

Le vrai combo : **Vectoriser + Classification**



Mesurer le **sentiment / opinion**
(de gauche ou de droite)



Détecter les **contenus**
toxiques, haineux ou
fake news



Classer automatiquement
les **événements** dans la presse

Notre petit programme de la matinée

1. Trois **concepts clefs** du Text Mining


2. Trois méthodes de **vectorisation**

1. Trois concept clefs du Text Mining



Obtention d'un corpus

Trois approches possibles pour collecter des données textuelles



2. Découpage en Tokens

Exemple

Tokenize on
rules

Let	's	tokenize	!	Is	n't	this	easy	?
-----	----	----------	---	----	-----	------	------	---

Tokenize on
punctuation

Let	'	s	tokenize	!	Isn	'	t	this	easy	?
-----	---	---	----------	---	-----	---	---	------	------	---

Tokenize on
white spaces


Let's	tokenize!	Isn't	this	easy?
-------	-----------	-------	------	-------

Let's tokenize! Isn't this easy?

<https://blog.floydhub.com/tokenization-nlp/>

2. Découpage en Tokens

Représentation « Bag of Words »



3. La matrice term-document

-  B. Sanders - [Combating, climate, change]
-  H. Clinton - [Let, start, the, combat, of, climate, change]
-  D. Trump - [Building, a, wall, letting, them, pay, for, the, wall]

tokens

	combating	climate	change	let	start	combat	of	building	a	wall	letting	them	pay	for	the
Trump	0	0	0	0	0	0	0	1	1	2	1	1	1	1	1
Sanders	1	1	1	0	0	0	0	0	0	0	0	0	0	0	0
Clinton	0	1	1	1	1	1	1	0	0	0	0	0	0	0	0

Matrice : 3 documents x 15 tokens

On va vouloir réduire le nombre de colonnes.

Pourquoi ?

Comment réduire ?

- **Nettoyage** du corpus (retrait des chiffres, harmonisation de la casse, etc.)
- Certains mots ne sont pas porteurs de sens (**stopwords**)
- Certains mots sont issus de la même forme canonique (**lemmatisation**)
- Certains mots partagent la même racine (**racinisation**)
- Certains mots sont **synonymes** ou recouvrent le même concept
- Certains mots apparaissent **très souvent** / **très rarement**

Exemple : 4 étapes de réduction

	Combating	climate	change	Let	start	combat	of	Building	a	wall	letting	them	pay	for	the
Trump	0	0	0	0	0	0	0	1	1	2	1	1	1	1	1
Sanders	1	1	1	0	0	0	0	0	0	0	0	0	0	0	0
Clinton	0	1	1	1	1	1	1	0	0	0	0	0	0	0	0

15 tokens

	combating	climate	change	let	start	combat	of	building	a	wall	letting	them	pay	for	the
Trump	0	0	0	0	0	0	0	1	1	2	1	1	1	1	1
Sanders	1	1	1	0	0	0	0	0	0	0	0	0	0	0	0
Clinton	0	1	1	1	1	1	1	0	0	0	0	0	0	0	0

Après (a)
15 tokens

	combating	climate	change	let	start	combat	building	wall	letting	pay
Trump	0	0	0	0	0	0	1	2	1	1
Sanders	1	1	1	0	0	0	0	0	0	0
Clinton	0	1	1	1	1	1	0	0	0	0

Après (b)
10 tokens

	combat	climat	chang	let	start	build	wall	pay
Trump	0	0	0	1	0	1	2	1
Sanders	1	1	1	0	0	0	0	0
Clinton	1	1	1	1	1	0	0	0

Après (c)
8 tokens

	combat	climat	chang	wall	let
Trump	0	0	0	2	1
Sanders	1	1	1	0	0
Clinton	1	1	1	0	1

Après (d)
5 tokens

La matrice devient plus facile à interpréter

Clustering des idéologies politiques

	combat	climat	chang	wall	let
Trump	0	0	0	2	1
Sanders	1	1	1	0	0
Clinton	1	1	1	0	1

bruit

clusters



Réduction supplémentaire possible
avec l'utilisation de n-grams

Que peut-on faire avec la matrice ?

Exemple : Macron vs Zemmour

Emmanuel Macron



Éric Zemmour



<https://nuagedemots.co/>

Que peut-on faire avec la matrice ?


Exemple 2 : tendance temporelle

<https://books.google.com/ngrams/>


2. Trois méthodes de **vectorisation**

Représentation vectorielle des documents

Exemple Twitter



Exemple Amazon



Méthode 1 : TF-IDF, la plus simple

On va associer aux tokens des poids pour **représenter leur valeur discriminante**

- **Importance** d'un token dans un document
(term frequency)
- **Spécificité** d'un token dans un corpus
(inverse document frequency)
- D'où le nom : **tf** x **idf**

Méthode 1 : TF-IDF, la plus simple

Titre article 1 - *Incubation period : risk study on the mean incubation period*

Titre article 2 – *Mean low risk period*

Titre article 3 – *The transmission risk : low transmissions*

TDM – Fréquence absolue

	incubation	period	assess	mean	low	risk	transmission
Article 1	2	2	1	1	0	1	0
Article 2	0	1	0	1	1	1	0
Article 3	0	0	0	0	1	1	2

Méthode 1 : TF-IDF, la plus simple

Etape 1 : mesure l'importance par la fréquence relative

TDM – Fréquence absolue

	incubation	period	assess	mean	low	risk	transmission
Article 1	2	2	1	1	0	1	0
Article 2	0	1	0	1	1	1	0
Article 3	0	0	0	0	1	1	2

TDM – Fréquence relative

	incubation	period	assess	mean	low	risk	transmission
Article 1	1	1	1/2	1/2	0	1/2	0
Article 2	0	1	0	1	1	1	0
Article 3	0	0	0	0	1/2	1/2	1

Méthode 1 : TF-IDF, la plus simple

Etape 2 : mesurer la spécificité

- **Discriminer** les tokens qui apparaissent dans beaucoup de documents

$$s_i = \left(\frac{|D|}{|D_i|} \right)$$

Méthode 1 : TF-IDF, la plus simple

Etape 2 : mesurer la spécificité

- **Discriminer** les tokens qui apparaissent dans beaucoup de documents

$$s_i = \log \left(\frac{|D|}{|D_i|} \right)$$

Méthode 1 : TF-IDF, la plus simple

En pratique...

TDM – TF (importances relatives) et IDF (spécificité)

	incubation	period	assess	mean	low	risk	transmission
Article 1	1	1	1/2	1/2	0	1/2	0
Article 2	0	1	0	1	1	1	0
Article 3	0	0	0	0	1/2	1/2	1
Specificity	1,1	0,41	1,1	0,41	0,41	0	1,1

Méthode 1 : TF-IDF, la plus simple

Résultat final

TDM – scores TF-IDF

	incubation	period	assess	mean	low	risk	transmission
Article 1	1,1	0,41	0,55	0,205	0	0	0
Article 2	0	0,41	0	0,41	0,41	0	0
Article 3	0	0	0	0	0,205	0	1,1


Méthode 1 : TF-IDF, la plus simple

Visualiser les vecteurs

TDM – scores TF-IDF

	incubation	period	assess	mean	low	risk	transmission
Article 1	1,1	0,41	0,55	0,205	0	0	0
Article 2	0	0,41	0	0,41	0,41	0	0
Article 3	0	0	0	0	0,205	0	1,1

Exemple de visualisation



Limites de la Méthode 1 (TF-IDF)

1. Perte du contexte

Chaque mot est traité indépendamment.

Impossible de distinguer banque (rivière) vs banque (finance).

2. Pas de relations sémantiques

“chat” et “félin” sont totalement différents dans l'espace vectoriel.

Limites de la Méthode 1 (TF-IDF)

3. Vecteurs gigantesques

Une dimension par mot → espace très large.

Sparsité extrême : des milliers de zéros.

4. Ignorent l'ordre des mots


Le chien mord l'homme = L'homme mord le chien

Vers les méthodes d'embeddings

- **Représentations denses:** vecteurs compacts (ex. 300–1024 dimensions), sans sparsité.
- **Appris automatiquement :** les vecteurs sont optimisés par un modèle (Word2Vec, GloVe, BERT, etc.).
- **Certains intègrent le contexte (polysémie) :**
Je développe une application en **Java**. : vecteur proche de python
Je voudrais voyager à **Java** en Indonésie : vecteur proche de Bali

Méthode 2 : Word2vec

Idée générale : prédire le mot suivant



On va s'entraîner à prédire un mot (intelligence) à l'aide d'un mot proche (artificial)

Limite de Word2vec

Word2Vec apprend **une seule représentation (un seul vecteur)** par mot.

Je développe une application en **Java**. : vecteur proche de python

Je voudrais voyager à **Java** en Indonésie : vecteur proche de Bali

- Il doit “**mélanger**” tous les usages du mot port dans un seul vecteur.
- Ce vecteur **reflète la moyenne** des contextes : maritime + obligation + informatique.
- Résultat : le vecteur n’est jamais parfaitement adapté à aucun sens particulier.

Méthode 3 : BERT

BERT = Bidirectional Encoder Representations from Transformers.

C'est un modèle de langage basé sur l'architecture **Transformer (partie encodeur)**

Avec Word2Vec :

- un mot → un seul vecteur (pas de contexte)

Avec BERT :

- un mot → un vecteur différent *dans chaque phrase*, selon le contexte.

Méthode 3 : BERT

Un mot sur le transformer

Exemple:

« entraîné pour de la
traduction sur un corpus
Français -> Allemand »





Figure 1: The Transformer - model architecture.

Méthode 3 : BERT

BERT est en réalité la partie encoder-only



Après, on peut calculer des distances et des similarités



Propriété d'une mesure de similarité

- Non-négativité $\text{sim}(i, j) \geq 0 \quad \forall i, j$
- Symétrie $\text{sim}(i, j) = \text{sim}(j, i) \quad \forall i, j$
- Maximalité $\text{sim}(i, i) \geq \text{sim}(i, j) \quad \forall i, j$

Possibilité de normaliser entre 0 et 1

Après, on peut calculer des distances et des similarités

La plus populaire : cosine similarity



	A1	A2	A3
A1			
A2			
A3			